

Tarea de Investigación y Desarrollo de un Análisis Exploratorio de Datos (EDA)

1. ¿Qué es el EDA y cuál es su propósito en el análisis de datos?

El **EDA (Exploratory Data Analysis)** es el proceso inicial del análisis de datos en el que se explora, limpia y comprende un conjunto de datos para descubrir patrones, detectar errores, identificar relaciones entre variables y obtener una visión general antes de aplicar modelos o técnicas más avanzadas.

Respuesta completa y bien explicada:

El **Análisis Exploratorio de Datos (EDA)** es una etapa fundamental dentro del análisis de datos. Consiste en **examinar un conjunto de datos de manera sistemática** para entender qué contiene, cómo está distribuido y qué problemas o patrones presenta.

Propósitos principales del EDA

- **Conocer la estructura del dataset:** cuántas filas, columnas, tipos de datos, valores faltantes, duplicados, etc.
- **Detectar errores o anomalías:** datos inconsistentes, outliers, valores imposibles.
- **Identificar patrones y tendencias:** distribuciones, comportamientos, agrupaciones.
- **Comprender relaciones entre variables:** correlaciones, dependencias, asociaciones.
- **Guiar decisiones posteriores:** qué modelo usar, qué variables son útiles, qué transformaciones aplicar.
- **Visualizar los datos** mediante gráficos (histogramas, boxplots, scatterplots, etc.) para interpretarlos mejor.

Ejemplo simple en Python (para entender el proceso)

`<p/>python`

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv("datos.csv")

df.head()      # Ver primeras filas
df.info()      # Ver tipos de datos y nulos
df.describe()  # Estadísticas básicas
sns.pairplot(df) # Visualizar relaciones entre variables
plt.show()
```

2. ¿Qué tipos de datos existen en un EDA?

En un Análisis Exploratorio de Datos (EDA), los datos se clasifican según **su naturaleza y cómo se pueden analizar**. Esta clasificación es clave porque determina qué gráficos, estadísticas y transformaciones se pueden aplicar.

Aquí tienes la explicación completa y bien organizada:

◆ 1. Datos Categóricos (o cualitativos)

Son datos que representan **categorías, grupos o etiquetas**, no cantidades.

Nominales → No tienen orden.

- Ejemplos:
 - Color: rojo, azul, verde
 - País: España, Perú, México
 - Género: masculino, femenino

Ordinales → Tienen un orden lógico.

- Ejemplos:
 - Talla de ropa: S < M < L
 - Nivel educativo: primaria < secundaria < universidad
 - Satisfacción: bajo, medio, alto

Se analizan con:

- Tablas de frecuencia
- Gráficos de barras
- Gráficos de pastel

◆ 2. Datos Numéricos (o cuantitativos)

Representan cantidades que se pueden medir o calcular.

Discretos → Son números enteros, no admiten decimales.

- Ejemplos:
 - Número de hijos
 - Cantidad de productos vendidos
 - Número de errores en un código

Continuos → Admiten decimales y pueden tomar infinitos valores dentro de un rango.

- Ejemplos:
 - Peso
 - Altura

- Temperatura
- Tiempo

Se analizan con:

- Histogramas
- Boxplots
- Medidas estadísticas (media, mediana, desviación estándar)

◆ 3. Datos Temporales (Time Series)

Son datos asociados a **fechas o tiempos**.

Ejemplos:

- Ventas por día
- Temperatura por hora
- Evolución del precio de una acción

Se analizan con:

- Gráficos de líneas
- Resampling (por día, semana, mes)
- Tendencias y estacionalidad

◆ 4. Datos Textuales

Son cadenas de texto que requieren procesamiento especial.

Ejemplos:

- Comentarios de usuarios
- Tweets
- Descripciones de productos

Se analizan con:

- Conteo de palabras
- Limpieza de texto
- Nubes de palabras

◆ 5. Datos Booleanos (True/False)

Solo tienen dos valores posibles.

Ejemplos:

- ¿Pagó? → Sí/No

- ¿Está activo? → True/False

Se analizan como categóricos.



Los tipos de datos más comunes en un EDA son:

- **Categóricos:** nominales y ordinales
- **Numéricos:** discretos y continuos
- **Temporales**
- **Textuales**
- **Booleanos**

Cada tipo de dato determina qué análisis y visualizaciones se pueden aplicar.

3. ¿Cuál es la diferencia entre análisis univariado, bivariado y multivariado?

El EDA puede analizar los datos desde distintos niveles de complejidad. La diferencia entre **univariado**, **bivariado** y **multivariado** depende del **número de variables** que se estudian al mismo tiempo.

◆ **Análisis univariado**

Estudia **una sola variable**.

¿Para qué sirve?

- Entender su distribución
- Detectar valores atípicos
- Ver rangos, medias, medianas, etc.

Ejemplos:

- Analizar solo la edad de los clientes
- Ver cuántas personas pertenecen a cada categoría de un producto

Gráficos típicos:

- Histogramas
- Boxplots
- Gráficos de barras

◆ **Análisis bivariado**

Estudia **dos variables al mismo tiempo** para ver si están relacionadas.

¿Para qué sirve?

- Identificar correlaciones
- Comparar una variable respecto a otra
- Ver cómo cambia una variable según otra

Ejemplos:

- Relación entre edad y salario
- Comparar ventas según tipo de producto
- Ver si el género influye en la satisfacción

Gráficos típicos:

- Scatter plots (dispersión)
- Gráficos de barras agrupadas
- Boxplots comparativos
- Mapas de calor de correlación

◆ **Análisis multivariado**

Estudia **tres o más variables al mismo tiempo**.

¿Para qué sirve?

- Entender relaciones complejas
- Detectar patrones entre múltiples factores
- Preparar datos para modelos predictivos

Ejemplos:

- Analizar cómo edad, salario y nivel educativo afectan el gasto
- Estudiar varias características de clientes para segmentarlos
- Ver correlaciones entre muchas variables a la vez

Gráficos típicos:

- Pairplots (seaborn)
- Mapas de calor de correlación
- Gráficos 3D
- Clustering (k-means)

Resumen

- **Univariado** → analiza **1 variable**.
- **Bivariado** → analiza **2 variables** y su relación.
- **Multivariado** → analiza **3 o más variables** para encontrar patrones complejos.

4. ¿Qué es la estadística descriptiva?

Respuesta

La **estadística descriptiva** es la rama de la estadística que se encarga de **resumir, organizar y describir** un conjunto de datos mediante **medidas numéricas** (como media, mediana, desviación estándar) y **representaciones gráficas** (como histogramas, boxplots o gráficos de barras).

Respuesta completa

La **estadística descriptiva** es una parte fundamental del Análisis Exploratorio de Datos (EDA). Su objetivo es **entender cómo se comportan los datos**, sin hacer predicciones ni inferencias, solo describiendo lo que está presente en el dataset.

¿Para qué sirve la estadística descriptiva?

- Resumir grandes cantidades de datos de forma clara
- Identificar patrones generales
- Detectar valores atípicos
- Comprender la distribución de las variables
- Facilitar la interpretación antes de aplicar modelos más complejos

◆ Principales medidas de la estadística descriptiva

Medidas de tendencia central

Describen el “centro” de los datos:

- **Media** (promedio)
- **Mediana** (valor central)
- **Moda** (valor más frecuente)

Medidas de dispersión

Indican qué tan separados están los datos:

- **Rango**
- **Varianza**
- **Desviación estándar**
- **Rango intercuartílico (IQR)**

Medidas de forma

Describen la forma de la distribución:

- **Asimetría (skewness)**
- **Curtosis (kurtosis)**

◆ Representaciones gráficas en estadística descriptiva

- Histogramas
- Boxplots
- Gráficos de barras
- Diagramas de violín
- Mapas de calor (para correlaciones)

☀ Resumen

La **estadística descriptiva** permite **describir y resumir** los datos mediante medidas numéricas y visualizaciones, ayudando a comprender su comportamiento antes de aplicar análisis más avanzados.

5. ¿Qué es la limpieza de datos y qué tareas suelen incluirse en este paso?

Respuesta corta

La **limpieza de datos** es el proceso de **corregir, depurar y preparar** un conjunto de datos para asegurar que sea **consistente, preciso y utilizable**. Incluye tareas como manejar valores nulos, eliminar duplicados, detectar outliers, corregir formatos y normalizar datos.

Respuesta completa

La **limpieza de datos** (data cleaning) es una etapa esencial del EDA. Su objetivo es **mejorar la calidad del dataset** para que los análisis y modelos posteriores sean confiables.

Los datos reales suelen venir con errores, valores faltantes, inconsistencias o formatos incorrectos, y este paso se encarga de solucionarlo.

◆ Manejo de valores nulos

Los valores nulos aparecen cuando falta información.

¿Qué se puede hacer?

- Eliminarlos (si son pocos)

- Reemplazarlos con la media, mediana o moda
- Usar técnicas de imputación
- Rellenarlos con valores por defecto

Ejemplo en pandas:

<p/>python

```
df.dropna()      # Eliminar filas con nulos
```

```
df.fillna(0)     # Rellenar con 0
```

```
df['edad'].fillna(df['edad'].mean()) # Rellenar con la media
```

◆ Eliminación de duplicados

A veces hay filas repetidas que distorsionan el análisis.

Ejemplo:

<p/>python

```
df.drop_duplicates()
```

◆ Detección y manejo de outliers

Los *outliers* son valores extremadamente altos o bajos que no encajan con el resto.

¿Qué se puede hacer?

- Detectarlos con boxplots o IQR
- Corregirlos si son errores
- Eliminarlos si afectan el análisis
- Transformarlos (log, sqrt)

◆ Corrección de tipos de datos

Ejemplos comunes:

- Fechas que aparecen como texto
- Números guardados como strings
- Booleanos mal formateados

Ejemplo:

<p/>python

```
df['fecha'] = pd.to_datetime(df['fecha'])
```



```
df['precio'] = df['precio'].astype(float)
```

◆ Normalización o estandarización

Se usa para que todas las variables estén en escalas comparables.

Ejemplos:

- Normalización (0 a 1)
- Estandarización (media 0, desviación 1)

◆ Corrección de formatos y valores inconsistentes

Ejemplos:

- “España”, “espana”, “ES” → deben unificarse
- “Hombre”, “M”, “masculino” → deben ser consistentes

☀ Resumen

La limpieza de datos incluye tareas como:

- Manejo de valores nulos
- Eliminación de duplicados
- Detección y tratamiento de outliers
- Corrección de tipos de datos
- Normalización o estandarización
- Unificación de formatos y categorías

Es un paso clave para asegurar que el análisis sea confiable.

6. ¿Qué papel juegan las librerías pandas, matplotlib y seaborn en un EDA?

En un Análisis Exploratorio de Datos (EDA), estas tres librerías cumplen funciones diferentes pero complementarias. Juntas permiten **cargar, limpiar, analizar y visualizar** los datos de forma eficiente.

◆ pandas → *Manipulación y limpieza de datos*

<pandas> es la librería principal para trabajar con datos en Python.

¿Para qué sirve en un EDA?

- Cargar datasets (CSV, Excel, SQL, JSON...)

- Limpiar datos (nulos, duplicados, outliers)
- Filtrar, ordenar y transformar columnas
- Calcular estadísticas descriptivas
- Crear nuevas variables

Ejemplos típicos:

```
python
df.head()
df.info()
df.describe()
df.dropna()
df['columna'].value_counts()
```

En resumen: pandas es el *corazón* del EDA porque permite preparar y explorar los datos.

◆ matplotlib → *Visualizaciones básicas*

Es la librería más clásica para crear gráficos en Python.

¿Para qué sirve en un EDA?

- Crear gráficos simples y personalizados
- Controlar colores, tamaños, títulos, ejes
- Base sobre la que trabajan otras librerías (como seaborn)

Ejemplos típicos:

```
python
plt.hist(df['edad'])
plt.plot(df['ventas'])
plt.bar(df['categoria'], df['cantidad'])
```

En resumen: matplotlib es la base para construir gráficos desde cero.

◆ seaborn → *Visualizaciones estadísticas avanzadas*

Seaborn está construido sobre matplotlib, pero es más moderno y estético.

¿Para qué sirve en un EDA?

- Crear gráficos estadísticos de forma sencilla
- Visualizar relaciones entre variables
- Detectar patrones, correlaciones y distribuciones
- Hacer gráficos más bonitos con menos código

Ejemplos típicos:

```
python
sns.boxplot(x='genero', y='salario', data=df)
sns.histplot(df['edad'])
sns.heatmap(df.corr(), annot=True)
sns.pairplot(df)
```

En resumen: seaborn es ideal para análisis bivariado y multivariado.

Resumen

pandas → manipulación, limpieza y análisis de datos.

- **matplotlib** → gráficos básicos y personalizables.
- **seaborn** → visualizaciones estadísticas avanzadas y estéticas.

Estas tres librerías juntas permiten realizar un EDA completo: **preparar, analizar y visualizar** los datos.

7. ¿Qué es una matriz de correlación y para qué sirve en el EDA?

Respuesta corta

Una **matriz de correlación** es una tabla que muestra el **grado de relación** entre varias variables numéricas. Sirve para identificar **patrones, tendencias, dependencias** y posibles **variables relevantes** para el análisis o modelos predictivos.

Respuesta completa

Una **matriz de correlación** es una estructura en forma de tabla donde cada celda representa el **coeficiente de correlación** entre dos variables numéricas.

Este coeficiente suele estar entre **-1 y 1**:

- **1** → correlación positiva perfecta
- **0** → no hay correlación
- **-1** → correlación negativa perfecta

◆ ¿Para qué sirve en un EDA?

1. Identificar relaciones entre variables

Permite ver si dos variables están relacionadas y en qué medida.

Ejemplos:

- A mayor edad, ¿aumenta el salario?
- A mayor temperatura, ¿bajan las ventas de café?

2. Detectar variables redundantes

Si dos variables tienen correlación muy alta (por ejemplo, 0.95), puede que aporten la misma información.

Esto es útil para:

- Simplificar modelos
- Evitar multicolinealidad

3. Seleccionar variables importantes

Ayuda a decidir qué variables pueden ser útiles para un modelo predictivo.

4. Detectar patrones generales en el dataset

La matriz permite ver rápidamente:

- Grupos de variables relacionadas
- Variables independientes
- Relaciones inesperadas

◆ ¿Cómo se visualiza en Python?

La forma más común es con un **heatmap** usando seaborn:

<p/>python

```
import seaborn as sns
```

```
import matplotlib.pyplot as plt
```

```
corr = df.corr()
```

```
sns.heatmap(corr, annot=True, cmap='coolwarm')
```

```
plt.show()
```

Resumen

Una **matriz de correlación** muestra cómo se relacionan las variables numéricas entre sí.

Sirve para:

- Identificar relaciones
- Detectar variables redundantes
- Seleccionar variables importantes
- Entender patrones del dataset

Es una herramienta clave para el análisis bivariado y multivariado.

8. ¿Qué son los outliers y qué métodos existen para detectarlos y tratarlos en un análisis exploratorio?

¿Qué son los outliers?

Los **outliers** son valores que se encuentran **muy alejados del resto de los datos**.

Son puntos “extraños” o “extremos” que no siguen el patrón general del dataset.

Pueden aparecer por:

- Errores de medición
- Datos mal ingresados
- Variaciones naturales extremas
- Comportamientos inusuales

Ejemplos:

- Una persona con 250 años (error)
- Un salario de 1.000.000 cuando la mayoría gana 1.500–3.000
- Un sensor que registra un pico anormal

Los outliers pueden **distorsionar** la media, la desviación estándar y algunos modelos, por eso es importante detectarlos.

Métodos para detectar outliers

♦ 1. Métodos gráficos

Son los más usados en EDA porque permiten ver los valores extremos visualmente.

- **Boxplot** → muestra valores fuera de los “bigotes”
- **Histogramas** → revelan valores muy alejados
- **Scatter plots** → útiles para ver outliers en dos variables

Ejemplo en Python:

<p/>python

```
sns.boxplot(x=df['edad'])
```

♦ 2. Método del IQR (Rango Intercuartílico)

Es uno de los métodos más comunes.

1. Calcular Q1 (25%) y Q3 (75%)
2. Calcular IQR = Q3 - Q1
3. Definir límites:
 - Inferior = $Q1 - 1.5 * IQR$
 - Superior = $Q3 + 1.5 * IQR$
4. Valores fuera de esos límites = outliers

Ejemplo:

<p/>python

```
Q1 = df['edad'].quantile(0.25)
```

```
Q3 = df['edad'].quantile(0.75)
```

```
IQR = Q3 - Q1
```

```
outliers = df[(df['edad'] < Q1 - 1.5*IQR) | (df['edad'] > Q3 + 1.5*IQR)]
```

♦ 3. Método Z-Score

Mide cuántas desviaciones estándar se aleja un valor de la media.

- Si $|Z| > 3 \rightarrow$ se considera outlier

Ejemplo:

<p/>python

```
from scipy import stats
```

```
z = np.abs(stats.zscore(df['edad']))
```

```
df[z > 3]
```

♦ 4. Métodos basados en modelos

Más avanzados, usados en datasets grandes.

- Isolation Forest
- DBSCAN

- Local Outlier Factor (LOF)

Métodos para tratar outliers

♦ 1. Eliminarlos

Si son errores evidentes o afectan demasiado el análisis.

♦ 2. Corregirlos

Cuando se sabe que el valor es incorrecto (ej.: 250 años → 25 años).

♦ 3. Transformarlos

Aplicar logaritmos, raíz cuadrada, etc., para reducir su impacto.

♦ 4. Reemplazarlos

Con la mediana o un valor razonable.

♦ 5. Dejarlos

Si representan casos reales importantes (ej.: clientes VIP).

☀ Resumen

Los **outliers** son valores extremos que se alejan del comportamiento normal de los datos.

Se detectan con:

- Boxplots
- Histogramas
- IQR
- Z-Score

Se tratan mediante:

- Eliminación
- Corrección
- Transformación
- Reemplazo
- Conservación (si son relevantes)

9. ¿Qué es hipótesis testing y para qué sirve en el EDA?

Respuesta corta

El **hypothesis testing** (prueba de hipótesis) es un proceso estadístico que permite **evaluar si una afirmación sobre los datos es verdadera o no**, usando evidencia numérica. En el EDA sirve para **comparar grupos, verificar supuestos, confirmar relaciones y tomar decisiones basadas en datos**.

Respuesta completa

El **hypothesis testing** es una técnica de la estadística inferencial que permite **comprobar si una idea o suposición sobre los datos tiene soporte estadístico**.

Aunque el EDA es principalmente exploratorio, las pruebas de hipótesis ayudan a **validar o descartar patrones** que parecen aparecer en los datos.

◆ ¿Qué es una hipótesis?

En estadística se plantean dos hipótesis:

- **Hipótesis nula (H_0)** → No hay diferencia, no hay efecto, no hay relación.
- **Hipótesis alternativa (H_1)** → Sí hay diferencia, sí hay efecto, sí hay relación.

El objetivo es decidir si los datos **apoyan** o **rechazan** la hipótesis nula.

◆ ¿Para qué sirve el hypothesis testing en un EDA?

1. Comparar grupos

Ejemplos:

- ¿El salario promedio de hombres y mujeres es diferente?
- ¿Dos productos tienen ventas medias distintas?

2. Verificar relaciones entre variables

Ejemplo:

- ¿Existe relación entre nivel educativo y tipo de empleo?

3. Validar patrones observados en gráficos

A veces un gráfico sugiere una diferencia, pero hay que confirmarla estadísticamente.

4. Tomar decisiones basadas en datos

Ayuda a evitar conclusiones basadas solo en intuición.

◆ Pruebas de hipótesis comunes en EDA

- **t-test** → compara medias entre dos grupos
- **ANOVA** → compara medias entre más de dos grupos
- **Chi-cuadrado** → analiza relación entre variables categóricas
- **Correlación de Pearson** → mide relación entre variables numéricas
- **Mann-Whitney** → alternativa no paramétrica al t-test

◆ Ejemplo simple en Python

<p/>python

```
from scipy.stats import ttest_ind

grupo1 = df[df['genero'] == 'H']['salario']
grupo2 = df[df['genero'] == 'M']['salario']

ttest_ind(grupo1, grupo2)
```

☀ Resumen

El **hypothesis testing** permite comprobar si una diferencia o relación observada en los datos es **estadísticamente significativa**.

En el EDA se usa para:

- Comparar grupos
- Validar patrones
- Confirmar relaciones
- Tomar decisiones basadas en evidencia

Parte 2: Práctica de Análisis Exploratorio de Datos

Siguiendo la guía a continuación, debes hacer paso a paso el análisis exploratorio de datos definido en ella, en un google collab.

Repositorio Práctico

Entrega

1. Subir un README a la organización de la promoción en github con tus respuestas.
2. En el repositorio donde subas tu README con las respuestas, debes subir el notebook con la práctica.